O que explica a avaliação de filmes e séries?

Uma análise com dados do IMDb em R

Nuno Silva (N.º 2022113056 · 2022113056@ufp.edu.pt)

Outubro de 2026

Seminário de Sistemas e Aplicações – UFP
M1: Introdução do projeto

Porquê este tema?

- Vejo filmes e séries com regularidade e uso o **IMDb** para decidir o que ver.
- Uma nota alta significa qualidade... ou apenas popularidade?
- Porque é que tantas séries parecem **piorar nas últimas temporadas**?
- Como programador web, interessa-me como estas plataformas **organizam e agregam** as avaliações de milhões de utilizadores.

O problema

Que características de um título – **género, duração, época, popularidade, tipo de produção** – estão associadas à sua **avaliação média**?

- E como evoluíram estes padrões **ao longo das décadas**?
- E **ao longo das temporadas** de uma série?

Fonte de dados: IMDb Non-Commercial Datasets

- Ficheiros **TSV** comprimidos, atualizados diariamente
- Acesso livre para uso pessoal e não comercial
- **Milhões** de títulos
- `datasets.imdbws.com`

Ficheiro	Variáveis principais
`title.basics`	tipo, título, ano, duração, géneros
`title.ratings`	nota média, n.º de votos
`title.episode`	série, temporada, episódio
`title.crew`	realizadores, argumentistas
`name.basics`	nomes das pessoas

Numéricas (contínuas e discretas), categóricas e temporais.

Como as tabelas se ligam

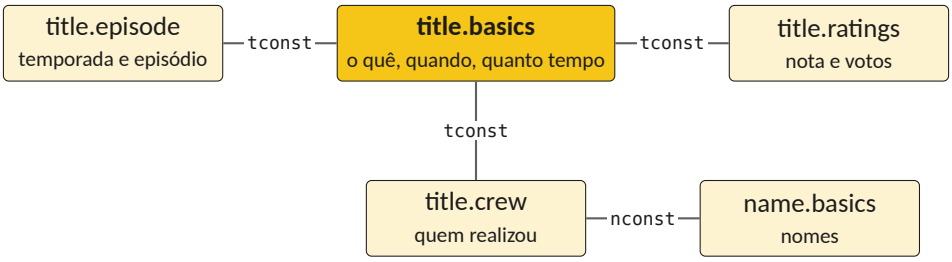

Várias tabelas ⇒ é preciso **cruzar e agregar** antes de analisar.

Os dados não vêm limpos

- Valores em falta codificados como `\N`
- Géneros numa só coluna: `"Drama,Crime,Thriller"`
- Duração e anos guardados como **texto**
- Filmes, séries, episódios, curtas e jogos misturados
- *Outliers*: durações absurdas, títulos com 5 votos

Volume enorme: o conjunto completo tem **milhões a dezenas de milhões de linhas** e vários GB. Vou quase de certeza **limitá-lo bastante** (por tipo de título e n.º mínimo de votos) para correr num portátil modesto.

As três perguntas analíticas

1. **Que fatores explicam a nota de um filme?**

   Regressão linear múltipla da nota em função de género, duração, década e n.º de votos — medir o peso de cada fator.

2. **A qualidade das séries desce ao longo das temporadas?**

   Cruzar `title.episode` com `title.ratings` e, por série, testar se a nota média por temporada sobe, mantém ou desce.

3. **Popularidade e qualidade andam juntas? Muda com o género?**

   Correlação entre n.º de votos e nota média, comparando a força da relação entre géneros.

Em pano de fundo, a evolução da duração e dos géneros por década dá contexto temporal às três.

Cumpre os critérios do guião?

Critério	IMDb
$\geq$ 1000 linhas, 6–8 variáveis	✓ milhões de linhas, mais de 10 variáveis úteis
Diversidade de tipos	✓ numéricas, categóricas e temporais (ano)
Exige *wrangling*	✓ omissos, listas, *joins*, *outliers*
Acesso público	✓ download direto por URL
$\geq$ 3 perguntas complexas	✓ 3 definidas: regressão, cruzamento de tabelas e correlação
Viabilidade	✓ subconjunto **fortemente filtrado** p/ correr num PC modesto

Ferramentas e próximos passos

Ferramentas

- R + RStudio
- `readr`, `dplyr`, `tidyr`
- `ggplot2`
- Quarto (relatório)
- Git / GitHub

Até ao M2

- Descarregar e explorar os ficheiros
- Definir o subconjunto (limitar bastante: tipo + n.º mínimo de votos)
- Dicionário de dados
- Fechar as 3–5 perguntas
- Criar o repositório Git

Obrigado!

Perguntas e sugestões?