O que explica a avaliação de filmes e séries? Uma análise com dados do IMDb

Seminário de Sistemas e Aplicações – UFP | M1: Introdução do projeto | Outubro de 2026
Autor: Nuno Silva | **N.º:** 2022113056 | **Email:** 2022113056@ufp.edu.pt

Domínio

Cinema e televisão (indústria do entretenimento e plataformas digitais de avaliação). O projeto analisa, em R, os dados públicos de uma plataforma do tipo IMDb – milhões de filmes, séries e episódios avaliados pelos próprios utilizadores.

Motivação e justificação pessoal

Vejo filmes e séries com regularidade e uso plataformas como o IMDb para decidir o que ver. Muitas vezes pergunto-me se uma nota alta reflete realmente qualidade ou apenas popularidade, e porque é que tantas séries parecem *perder qualidade* nas últimas temporadas. Como programador web, interessa-me também perceber como estas plataformas estruturam e agregam as avaliações de milhões de utilizadores. Este projeto junta essas duas curiosidades num problema concreto.

Problema

Identificar **que características de um título (género, duração, época de lançamento, popularidade, tipo de produção) estão associadas à sua avaliação média**, e perceber como estes padrões evoluíram ao longo das décadas e ao longo das temporadas das séries.

Potencial fonte de dados

IMDb Non-Commercial Datasets: ficheiros TSV comprimidos, atualizados diariamente e de acesso livre para uso pessoal e não comercial, ligados entre si pelo identificador `tconst`.
Dados: `https://datasets.imdbws.com/` Documentação: `https://developer.imdb.com/non-commercial-datasets/`

Ficheiro	Conteúdo	Variáveis principais
`title.basics`	todos os títulos (milhões de linhas)	tipo, título, ano, duração, géneros
`title.ratings`	avaliações agregadas	nota média, n.º de votos
`title.episode`	ligação episódio → série	série, temporada, episódio
`title.crew` / `name.basics`	realizadores e argumentistas	identificadores e nomes

Mistura variáveis numéricas contínuas (nota) e discretas (votos, duração, temporada), categóricas (tipo, géneros) e temporais (ano). Os dados **exigem preparação real**: valores em falta codificados como `\N`, géneros em listas separadas por vírgulas, duração guardada como texto, cruzamento de várias tabelas, filtragem de tipos (filmes, séries, episódios) e tratamento de *outliers* (durações absurdas, títulos com poucos votos).

Perguntas analíticas

1. **Que fatores explicam a nota média de um filme?** Modelo de regressão linear múltipla da nota em função de género, duração, década e número de votos, para medir o peso relativo de cada fator. *(modelação)*
2. **A avaliação das séries sobe, mantém-se ou desce ao longo das temporadas?** Cruzamento de `title.episode` com `title.ratings` e teste da tendência da nota média por temporada dentro de cada série. *(cruzamento de tabelas + inferência)*
3. **Existe relação entre popularidade (n.º de votos) e qualidade percebida, e varia por género?** Correlação entre votos e nota média, comparando a força da relação entre géneros. *(correlação + comparação de grupos)*

Como leitura de contexto, a evolução da duração média e do peso de cada género ao longo das décadas acompanha estas três perguntas.

Ferramentas e viabilidade

R e RStudio (`readr`, `dplyr`, `tidyr`, `ggplot2`), Quarto para o relatório e Git/GitHub para versionamento. O conjunto completo é **enorme** (vários GB, até dezenas de milhões de linhas), pelo que — para garantir viabilidade num computador pessoal modesto e reprodutibilidade — a análise será feita sobre um **subconjunto fortemente filtrado** (ex.: apenas certos tipos de título e com um número mínimo de votos), com o *script* de download e filtragem incluído no repositório.