Do pitch à validação dos dados

Avaliação de filmes e séries com dados do IMDb em R

Nuno Silva (N.º 2022113056 · 2022113056@ufp.edu.pt)

Outubro de 2026

Seminário de Sistemas e Aplicações – UFP
M2: Apresentação do problema

Onde estamos

Problema: que características de um título – género, duração, época, popularidade – estão associadas à sua **avaliação média**, e como evoluíram ao longo do tempo?

No M1 apresentei a ideia. Neste M2 trago:

- as **perguntas de investigação** fechadas,
- o **dicionário de dados** validado,
- o **repositório Git** criado e os dados disponíveis.

Perguntas de investigação

1. Que características de um filme (género, duração, década, votos) explicam a sua **nota média**?
   → regressão linear múltipla

2. A avaliação das **séries** sobe, mantém-se ou desce ao longo das **temporadas**?
   → junção episódio → série + análise de tendência

3. **Popularidade** (votos) e **qualidade** (nota) estão relacionadas? Varia por género?
   → correlação e comparação entre grupos

4. Como evoluíram a **duração** e o peso de cada **género** ao longo das décadas?
   → agregação temporal

Nenhuma se responde por simples somas ou contagens.

Fonte de dados: IMDb Non-Commercial Datasets

- Ficheiros **TSV** comprimidos, atualizados diariamente
- Acesso livre, uso pessoal e não comercial
- **Milhões** de títulos
- Ligados pelo identificador `tconst`
- `datasets.imdbws.com`

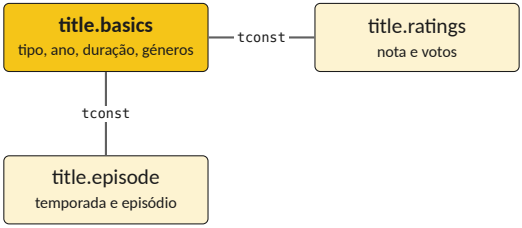

Três ficheiros centrais, cruzados por `tconst`.

Dicionário de dados (variáveis principais)

Variável	Ficheiro	Tipo	Papel na análise
averageRating	ratings	numérica contínua	variável-resposta
numVotes	ratings	inteiro	popularidade
genres	basics	categórica (lista)	género
runtimeMinutes	basics	inteiro	duração
startYear	basics	temporal (ano)	época / década
titleType	basics	categórica	filme / série / episódio
seasonNumber	episode	inteiro	temporada (séries)

Numéricas, categóricas e temporais – 8+ variáveis relevantes após as junções.

Validação: os dados não vêm limpos

- Omissos codificados como `\N`
- `genres` numa só coluna: `"Drama,Crime"`
- Duração e anos guardados como **texto**
- Tipos misturados: filmes, séries, episódios, curtas, jogos
- *Outliers* de duração; títulos com pouquíssimos votos
- Volume grande $\Rightarrow$ filtrar um subconjunto viável

Tudo documentado no dicionário de dados; a limpeza é o trabalho do M3.

O repositório Git

```
SSAP-MINF-2022113056/
 README.md
 .gitignore
 data/
   raw/        (dados, nao versionados)
 docs/
   perguntas-investigacao.md
   dicionario-de-dados.md
 scripts/
   01_download_dados.R
```

- Público, no GitHub
- Dados brutos **fora** do Git (demasiado grandes)
- Obtidos por **script** reprodutível
- **Caminhos relativos** em todo o código

Cumpre os critérios do guião

Critério	Estado
3–5 perguntas de investigação	✓ 4 perguntas, com técnica associada
Dicionário de dados	✓ ficheiros, variáveis, tipos e notas de qualidade
Repositório Git criado	✓ público, com estrutura e README
Dataset disponível	✓ via URL oficial + script de download
$\geq$ 1000 linhas, 6–8 variáveis	✓ centenas de milhares de linhas, 8+ variáveis

Próximos passos (M3)

- Instalar o ambiente R + RStudio e correr o script de download
- Limpeza (*wrangling*): omissos, tipos, separação de géneros, *outliers*
- Definir o subconjunto de análise (filtros de tipo e de votos)
- Estatística descritiva e, no mínimo, 3 visualizações em `ggplot2`
- Relatório reprodutível em Quarto

Obrigado!

Perguntas e sugestões?